

RAPPORT TECHNIQUE

DirVAE vs GVAE — Évaluation Équitable

Comparaison sur NIH DeepLesion :
reconstruction, clustering et disentanglement

Dataset

NIH DeepLesion, 8 types anatomiques, ~77M paramètres

Date

10 Mai 2026

Bezot Camille, Brasa Franklin, Kenmogne Loïc, Martins Soares Flavio
ING3 IA A

A l'attention de Mr. Arthur Satouf

1. Introduction

Contexte : apprendre des représentations latentes en imagerie médicale

Les **Variational Autoencoders (VAE)** sont devenus un outil central pour la représentation non supervisée d'images médicales. Leur principe : encoder une image x en une distribution dans un espace latent compact z , puis décoder z pour reconstruire x . L'espace latent ainsi appris peut servir à détecter des anomalies, générer des images synthétiques pour augmenter les données, ou séparer des facteurs de variation cliniquement pertinents (taille d'une lésion, organe touché, niveau de malignité).

Le verrou principal du VAE gaussien standard est que son prior $p(z) = \mathcal{N}(0, I)$ ne contraint pas la structure de l'espace latent : les dimensions peuvent être redondantes ou entremêlées, rendant l'espace difficile à interpréter et à exploiter pour des tâches aval.

Le papier DirVAE, Joo et al. (2020, Pattern Recognition)

Pour résoudre ce problème, Joo et al. proposent de remplacer le prior gaussien par un **prior Dirichlet** $\text{Dir}(\alpha)$, qui contraint le vecteur latent z à vivre sur le **simplexe standard** : toutes les coordonnées sont positives et leur somme vaut 1. Cette contrainte géométrique a deux effets théoriques recherchés : (1) la **sparsité**, chaque exemple n'active qu'un sous-ensemble réduit de dimensions latentes, les autres restant proches de zéro, et (2) le **disentangling**, chaque dimension active tend à capturer un facteur de variation indépendant et interprétable (ici : le type d'organe, la densité HU, la forme de la lésion).

Sur le plan technique, le DirVAE remplace la tête gaussienne ($\mu, \log \sigma^2$) par une tête qui prédit des log-concentrations α passées par softplus pour garantir $\alpha > 0$. L'échantillonnage utilise `Dirichlet.sample()`, une implémentation différentiable compatible avec la backpropagation. La divergence KL entre la distribution Dirichlet encodée et le prior $\text{Dir}(\alpha_0)$ remplace la KL gaussienne dans l'ELBO, pondérée par un coefficient β annealed.

Hypothèse testée : dans un cadre de comparaison strictement équitable (même architecture, même durée, même dataset), le prior Dirichlet produit-il un espace latent plus structuré, plus séparable par organe (NMI, CLASSIX), et avec un meilleur disentangling (MIG), quitte à sacrifier légèrement la qualité de reconstruction ?

2. Dataset

NIH DeepLesion recense 32 735 lésions annotées sur scanners CT couvrant **8 types anatomiques** : os (1), abdomen (2), médiastin (3), foie (4), poumon (5), rein (6), tissu mou (7), pelvis (8). Après filtrage par fichiers disponibles sur disque, on obtient **1 124 patches train / 226 val / 414 probe**. Le **probe set** (414 images, jamais vues à l'entraînement) est réservé exclusivement à l'analyse de l'espace latent et aux métriques de disentangling, garantissant une évaluation sans biais de mémorisation.

Prétraitement : chaque patch est extrait via un crop sur la bounding box annotée (+10 px de padding), les pixels sont convertis en unités Hounsfield (UH = valeur PNG - 32 768), clippés dans $[-1\ 000 ; +500\ \text{UH}]$ et normalisés dans $[0, 1]$. Chaque image est redimensionnée en **64×64 pixels** par interpolation bilinéaire.




Figure 1 — Exemples de patches DeepLesion après prétraitement (64×64, normalisés HU, 8 types anatomiques)

3. Architecture et Entraînement

3.1 Architecture commune, encodeur et décodeur

Les deux modèles partagent **exactement le même squelette convolutif** (~77M paramètres chacun), garantissant que toute différence de performance est imputable au prior et non à la capacité du modèle. L'encodeur est composé de **7 blocs Conv2d successifs** avec stride=2 (sous-échantillonnage $\times 2$ à chaque bloc), activation GELU et BatchNorm2d. La carte de features 4×4 résultante est aplatie et projetée via une couche dense vers un **bottleneck de 2 048 neurones**. C'est à partir de ce bottleneck que divergent les deux architectures.

Le décodeur est le miroir exact de l'encodeur : 7 blocs ConvTranspose2d (stride=2, GELU, BN) remontent progressivement vers l'image 64×64, avec une convolution finale 1×1 et une activation Sigmoid pour borner la sortie dans [0, 1].

Composant	Couches	GVAE — tête latente	DirVAE — tête latente
Encodeur conv.	7 × Conv2d	Partagé (identique)	Partagé (identique)
Activations	GELU + BN	Partagé	Partagé
Bottleneck	FC → 2048	Partagé	Partagé
Tête latente	FC → 256	$\mu_{fc} + \log \text{var}_{fc} (\times 2)$	$\alpha_{fc} (\times 1, \text{softplus})$
Sampling	/	$z = \mu + \varepsilon \cdot \sigma, \varepsilon \sim \mathcal{N}(0, I)$	$z \sim \text{Dir}(\alpha), \text{rsample}()$
KL divergence	/	$-\frac{1}{2} \cdot \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$	$\text{KL}(\text{Dir}(\alpha) \parallel \text{Dir}(\alpha_0))$
Décodeur conv.	7 × ConvTranspose 2d	Partagé (identique)	Partagé (identique)
Params totaux	/	76 675 841	76 610 049

3.2 Fonctions de perte

La loss d'entraînement est l'ELBO combinant reconstruction et régularisation latente :

$$\mathcal{L} = 0.5 \cdot L1(x, \hat{x}) + 0.5 \cdot (1 - \text{SSIM}(x, \hat{x})) + \beta_{\text{annealed}} \cdot \text{KL}$$

La **reconstruction** combine L1 (robuste aux outliers) et SSIM (perceptuel, sensible aux structures spatiales) à poids égaux. La **KL gaussienne** a une forme analytique fermée : $\text{KL} = -\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$. La **KL Dirichlet** est calculée entre $\text{Dir}(\alpha \text{ encodé})$ et le prior $\text{Dir}(\alpha_0 = 0.99)$ via les fonctions Gamma et digamma, nettement plus coûteuse et sensible à l'initialisation.

3.3 Stratégie d'entraînement, β -annealing

L'entraînement dure **150 epochs** (Tesla T4, batch=64, LR=5e-5, Adam). Le coefficient β est appliqué avec un **annealing linéaire de 0 → 5 sur les 30 premières epochs**, puis fixé à 5. Cette stratégie est critique pour le DirVAE : démarrer avec $\beta=0$ permet au décodeur de se spécialiser sur la reconstruction avant que la KL Dirichlet (très forte à l'initialisation) n'effondre le prior. Sans annealing, le DirVAE converge vers un posterior collapse dès les premières itérations. Un scheduler ReduceLROnPlateau (patience=10, factor=0.5) ajuste le LR si la val loss stagne.




Figure 2 — Courbes d'entraînement sur 150 epochs : DirVAE (gauche) et GVAE (droite) — loss totale, recon et SSIM val

Observation : le DirVAE démarre avec une loss très élevée (KL Dirichlet ≈ 35 à l'epoch 1 contre ≈ 12 pour le GVAE), signe que le prior Dirichlet est initialement très éloigné du posterior encodé. Les deux modèles atteignent un SSIM val de ≈ 0.66 dès l'epoch 4-5 et se stabilisent ensuite — indiquant que la reconstruction est rapide mais que la régularisation latente converge plus lentement.

4. Résultats

4.1 Métriques quantitatives globales

Métrique	DirVAE	GVAE
Recon val (↓)	186.46	179.91
SSIM val (↑)	0.6651	0.6557
NMI K-Means organe (↑)	0.2816	0.3350
NMI CLASSIX organe (↑)	0.3694	0.4006
MIG organe (↑)	0.0017	0.0169

Verdict : GVAE gagne 4 métriques sur 5. La reconstruction est légèrement meilleure (recon val -3.5% , soit 179.9 vs 186.5). Le SSIM val est le seul point où le DirVAE l'emporte (+0.94 pt), suggérant des reconstructions légèrement mieux lissées perceptuellement. Sur le clustering par organe, le GVAE domine : NMI K-Means $+18.9\%$ (0.3350 vs 0.2816), NMI CLASSIX $+8.4\%$ (0.4006 vs 0.3694). L'écart le plus frappant est le **MIG : 0.0169 vs 0.0017, soit un ratio de $\times 10$** en faveur du GVAE, ce qui signifie que les dimensions du GVAE capturent de façon bien plus exclusive les variations de type d'organe.

4.2 Structure de l'espace latent, UMAP

Les projections UMAP ($n_neighbors=15$, $min_dist=0.1$) sur les 414 samples du probe set, colorées par type anatomique, révèlent comment chaque modèle organise l'espace latent à 256 dimensions. Une bonne séparation des couleurs indique que le modèle encode l'information anatomique de façon discriminante.

Comparaison espaces latents — DirVAE vs GVAE




Figure 3 — UMAP coloré par organe (414 samples probe set). Haut : DirVAE. Bas : GVAE. Les deux forment des îlots partiels.

4.3 MIG et traversées sémantiques

Le MIG (Mutual Information Gap) mesure, pour chaque facteur génératif (ici le type d'organe), la différence entre l'information mutuelle de la meilleure dimension latente et celle de la deuxième meilleure : un score élevé indique qu'une seule dimension monopolise l'encodage de ce facteur (bon disentanglement). Le GVAE obtient un MIG de **0.0169** contre **0.0017** pour le DirVAE, le prior Dirichlet, censé favoriser la sparsité, n'améliore pas l'exclusivité de l'encodage.




Figure 4 — Score MIG par dimension. Le GVAE (droite) présente un pic plus net : une dimension encode davantage le type d'organe.

Les traversées sémantiques 5×5 naviguent dans l'espace latent le long de deux directions calculées : la direction Lung–Liver (différence des centroïdes de z pour les lésions pulmonaires vs hépatiques) et la direction malignité. Chaque cellule de la grille correspond à un $z = \bar{z} + a_o \cdot v_{organe} + a_m \cdot v_{malig}$, décodé en image.




Figure 5 — Traversées sémantiques 5×5 (organe × malignité, de -2σ à $+2\sigma$). Haut : DirVAE. Bas : GVAE.

5. Discussion et Conclusion

Un résultat négatif, mais riche d'enseignements

Le résultat central de cette étude est **contre-intuitif** : le GVAE gaussien surpasse le DirVAE sur 4 métriques sur 5, y compris le MIG qui mesure précisément la qualité du disentanglement — la promesse fondamentale du papier Joo et al. Ce résultat ne signifie pas que l'approche Dirichlet est inefficace, mais il révèle les conditions dans lesquelles elle ne parvient pas à exprimer son potentiel.

Pourquoi le DirVAE sous-performe ici ?

Plusieurs facteurs expliquent ces résultats :

- Posterior collapse partiel : malgré le β -annealing, la KL Dirichlet reste très élevée (~ 35 nats à l'epoch 1). Avec 1 124 images d'entraînement, le modèle ne dispose pas de suffisamment d'exemples pour que le posterior Dirichlet converge vers un régime sparse et structuré. Le collapse se manifeste par un espace latent peu différencié sur le probe set (Figure 3, UMAP DirVAE)
- Incompatibilité prior/données : le prior Dir(0.99) avec $\alpha_0 < 1$ impose une distribution en U sur le simplexe (masse aux coins), favorisant des représentations one-hot. Or les lésions médicales sont des entités continues — cette contrainte trop rigide pénalise la reconstruction de textures fines
- Facteur génératif discret mal adapté au MIG : le MIG est calculé en discrétisant les dimensions latentes continues. Cette discrétisation peut systématiquement sous-évaluer le DirVAE si ses représentations, bien que plus structurées, sont réparties sur des plages de valeurs différentes de celles du GVAE
- Absence de facteur de malignité : le label 'possibly_noisy' est constant à zéro dans ce subset, réduisant l'évaluation du disentanglement à un seul facteur catégoriel (organe) — insuffisant pour tester la capacité du DirVAE à séparer des facteurs continus indépendants

Conclusion et perspectives

Sur ce benchmark de **1 124 images DeepLesion** avec une architecture ~ 77 M paramètres entraînée 150 epochs, le GVAE s'impose comme le modèle le plus performant et le mieux disentangled. Cependant, ce résultat doit être interprété comme un **finding négatif préliminaire** plutôt qu'une réfutation définitive du DirVAE. Les pistes concrètes pour renverser ce constat sont : **(1)** abaisser α_0 (ex. 0.1–0.5) pour un prior Dirichlet moins contraignant, **(2)** allonger l'annealing sur 50–80 epochs pour laisser le temps au posterior Dirichlet de s'organiser, **(3)** augmenter le volume de données (dataset complet : 32 735 lésions), **(4)** utiliser de vrais labels de malignité pour évaluer le disentanglement multi-facteurs, et **(5)** valider sur une tâche aval (classification par organe depuis z seul) pour juger l'utilité clinique réelle de chaque espace latent.